

Material Didático:

Uso de Bagging para Melhorar Agrupamento de Formas Tridimensionais
Baseado em Nascimento, Ospina e Amorim (2024)

Material de Apoio para Mestrado em Estatística
Análise Multivariada e Análise de Formas

14 de maio de 2026

Resumo

Este material didático apresenta, de forma detalhada e gradual, os conceitos fundamentais necessários para compreender o artigo “Using Bagging to improve clustering methods in the context of three-dimensional shapes” (Nascimento et al., 2024). O texto é destinado a estudantes de mestrado e assume conhecimento básico de estatística, mas explica todos os conceitos específicos de análise de formas, algoritmos de agrupamento e métodos de ensemble. Incluímos exemplos numéricos, ilustrações conceituais e discussões sobre as escolhas metodológicas do artigo.

Sumário

1	Introdução: Por que Analisar Formas?	3
1.1	O Problema Central	3
1.2	Desafios Específicos	3
2	Fundamentos de Análise de Formas	3
2.1	Configurações e Marcos (Landmarks)	3
2.2	O Problema das Similaridades Euclidianas	4
2.3	Passo 1: Removendo a Localização (Centragem)	4
2.4	Passo 2: Removendo a Escala (Normalização)	5
2.5	Passo 3: O Espaço de Formas (Quociente por Rotações)	5
2.6	Geometria do Espaço de Formas	5
3	Distâncias em Análise de Formas	6
3.1	Distância Riemanniana Completa	6
3.2	Distância de Procrustes Completa	6
4	Agrupamento (Clustering) de Formas	6
4.1	O Que é Análise de Agrupamentos?	7
4.2	Métodos Hierárquicos vs. Particionais	7

5	Métodos de Agrupamento Detalhados	7
5.1	K-médias (K-means)	7
5.2	CLARANS: Clustering baseado em Medoides	8
5.3	Hill Climbing (Subida/descida da encosta)	9
6	O Método Bagging	9
6.1	Motivação: Por que Bagging?	9
6.2	Bootstrap: Fundamento Teórico	9
6.3	Bagging para Agrupamento (BagClust1)	10
7	Validação de Agrupamentos	10
7.1	Índice de Rand (RI)	10
7.2	Índice de Fowlkes-Mallows (FMI)	11
7.3	Teste de Wilcoxon Pareado	11
8	Estudo de Simulação do Artigo	12
8.1	Design Experimental	12
8.2	Resultados Principais	12
9	Aplicações em Dados Reais	13
9.1	Crânios de Macacos ($N = 18$)	13
9.2	Cérebros Humanos ($N = 58$)	13
10	Conclusões e Recomendações Práticas	13
10.1	Checklist para Aplicação	13
10.2	Extensões Futuras	14
11	Glossário de Termos	14
12	Referências e Leituras Complementares	15

1 Introdução: Por que Analisar Formas?

Contexto Motivador

Imagine que você é um paleontólogo e encontrou fósseis de crânios de diferentes espécies de dinossauros. Como determinar se dois crânios pertencem à mesma espécie ou a espécies diferentes? O tamanho pode não ser suficiente (dois indivíduos da mesma espécie podem ter tamanhos diferentes). A **forma** — a estrutura geométrica independente de escala — é frequentemente mais informativa.

1.1 O Problema Central

A análise estatística de formas (*Statistical Shape Analysis*) lida com objetos onde a geometria é a informação relevante. Exemplos de aplicações:

- **Medicina:** Comparar formas de órgãos (coração, cérebro) entre pacientes saudáveis e doentes
- **Biologia:** Classificar espécies baseando-se na morfologia de estruturas anatômicas
- **Engenharia:** Análise de qualidade de peças manufacturadas
- **Arqueologia:** Comparar artefatos de culturas diferentes

1.2 Desafios Específicos

Por que formas 3D são mais difíceis que 2D?

O artigo enfatiza que passar de formas 2D para 3D não é apenas “adicionar uma dimensão”. O **espaço de formas 3D** tem uma estrutura matemática mais complexa chamada **espaço estratificado**, que contém **singularidades** — pontos onde a geometria do espaço muda abruptamente.

Analogia intuitiva: Imagine uma esfera (variedade suave) versus um cone (singularidade no vértice). Em 2D, o espaço de formas é uma esfera suave. Em 3D, é como uma esfera com “dobras” e “picos” onde os métodos estatísticos tradicionais podem falhar.

2 Fundamentos de Análise de Formas

2.1 Configurações e Marcos (Landmarks)

Definição 2.1 (Configuração). Uma **configuração** é uma coleção de k pontos (chamados **marcos** ou *landmarks*) em $\mathbb{R}^m$, representada por uma matriz X de dimensão $k \times m$:

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1m} \\ x_{21} & x_{22} & \cdots & x_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ x_{k1} & x_{k2} & \cdots & x_{km} \end{bmatrix}$$

Cada linha representa as coordenadas de um marco no espaço m -dimensional.

Exemplo 2.1 (Crânio de Macaco). No artigo, os autores analisam crânios de macacos *Macaca fascicularis* com $k = 7$ marcos anatômicos em 3 dimensões ($m = 3$):

1. Prosthion (ponto frontal)
2. Nasion (junta nasal)
3. Bregma (junta coronária)
4. Opisthion (ponto posterior)
5. Asterion (ponto lateral)
6. Interfrontomolare (ponto orbitário)
7. Midpoint (ponto médio)

Cada crânio é uma matriz 7×3 .

2.2 O Problema das Similaridades Euclidianas

A matriz X **não** define unicamente uma forma porque depende de:

- **Localização (Translação):** Onde o objeto está no espaço
- **Escala:** O quão grande o objeto é
- **Rotação:** A orientação do objeto

Exemplo Visual

Considere a mesma cadeira fotografada em duas posições:

- Cadeira A: no canto da sala, vista de frente, a 2 metros
- Cadeira B: no centro da sala, vista de lado, a 3 metros

As coordenadas dos pixels são completamente diferentes, mas a **forma** da cadeira é idêntica. Precisamos remover essas “nuisance parameters” (parâmetros incômodos).

2.3 Passo 1: Removendo a Localização (Centragem)

Definição 2.2 (Matriz de Helmert). A **submatriz de Helmert** H é uma matriz $(k-1) \times k$ que transforma coordenadas removendo o efeito de translação. É obtida removendo-se a primeira linha da matriz de Helmert completa.

Para $k = 3$ marcos em 2D:

$$H = \begin{bmatrix} -1/\sqrt{2} & 1/\sqrt{2} & 0 \\ -1/\sqrt{6} & -1/\sqrt{6} & 2/\sqrt{6} \end{bmatrix}$$

Multiplicar HX centraliza os dados no centro de gravidade.

Observação 2.1 (Por que Helmert?). A matriz de Helmert é ortogonal ($H^T H = I$) e garante que a transformação preserve distâncias (isometria). Outras formas de centralização existem, mas Helmert é padrão na literatura de análise de formas por propriedades matemáticas convenientes.

2.4 Passo 2: Removendo a Escala (Normalização)

Definição 2.3 (Pré-forma). Dada uma configuração X , sua **pré-forma** Z é obtida por:

$$Z = \frac{HX}{\|HX\|} \quad (1)$$

onde $\|HX\| = \sqrt{\text{tr}((HX)^T(HX))}$ é a norma de Frobenius.

O conjunto de todas as pré-formas é chamado de **espaço de pré-formas** $\mathcal{S}_m^k$.

O que foi removido até agora?

- ✓ Translação (via Helmert)
- ✓ Escala (via normalização)
- × Rotação (ainda presente!)

A pré-forma Z ainda pode ser rotacionada arbitrariamente. Duas pré-formas Z_1 e Z_2 representam a mesma forma se diferirem apenas por uma rotação.

2.5 Passo 3: O Espaço de Formas (Quociente por Rotações)

Definição 2.4 (Espaço de Formas). O **espaço de formas** Σ_m^k é o conjunto de classes de equivalência de pré-formas sob rotação:

$$[Z] = \{Z\Gamma : \Gamma \in SO(m)\} \quad (2)$$

onde $SO(m)$ é o grupo especial ortogonal (matrizes de rotação $m \times m$ com determinante +1).

Analogia: Fotos da Mesma Pessoa

Imagine várias fotos da mesma cadeira tiradas de ângulos diferentes (rotações). Cada foto é uma pré-forma diferente, mas todas pertencem à mesma classe $[Z]$ no espaço de formas. A análise de formas trabalha com essas classes, não com as pré-formas individuais.

2.6 Geometria do Espaço de Formas

Proposição 2.1 (Estrutura Geométrica). O espaço de pré-formas $\mathcal{S}_m^k$ é uma hipersfera de raio unitário em $\mathbb{R}^{(k-1)m}$ (variedade riemanniana bem comportada).

Porém, o espaço de formas Σ_m^k para $m \geq 3$ é um **espaço estratificado** — não é uma variedade suave, contém singularidades.

Observação 2.2 (Implicações Práticas). Isso significa que:

1. Não podemos usar estatística euclidiana “ingênua” (médias aritméticas simples)
2. O cálculo de médias requer otimização em espaços não-lineares
3. Para $m = 2$ (formas planas), a teoria é mais simples; para $m = 3$, há complexidades adicionais

3 Distâncias em Análise de Formas

Para comparar formas, precisamos de uma noção de distância no espaço de formas.

3.1 Distância Riemanniana Completa

Definição 3.1 (Distância Riemanniana). A **distância riemanniana** $\rho(X_1, X_2)$ entre duas configurações é o menor ângulo (geodésica) entre suas pré-formas na hipersfera $\mathcal{S}_m^k$, otimizando sobre todas as rotações:

$$\rho(X_1, X_2) = \inf_{\Gamma \in SO(m)} \arccos(\langle Z_1, Z_2 \Gamma \rangle) \quad (3)$$

onde $\langle A, B \rangle = \text{tr}(A^T B)$ é o produto interno de Frobenius.

Exemplo 3.1 (Cálculo Simplificado). Para duas pré-formas Z_1 e Z_2 na hipersfera unitária:

1. Calcular a matriz de covariância: $S = Z_1^T Z_2$
2. Decompor em valores singulares (SVD): $S = U D V^T$
3. A distância é: $\rho = \arccos(\sum_{i=1}^m d_i)$, onde d_i são os valores singulares

O SVD resolve automaticamente o problema de alinhamento por rotação!

3.2 Distância de Procrustes Completa

Definição 3.2 (Distância de Procrustes). A **distância de Procrustes completa** d_F inclui também otimização sobre escala:

$$d_F(X_1, X_2) = \inf_{\Gamma \in SO(m), \beta > 0} \|Z_2 - \beta Z_1 \Gamma\| \quad (4)$$

Relação com a distância riemanniana:

$$d_F = \sin(\rho) \quad (5)$$

Mitologia de Procrustes

Na mitologia grega, Procrustes era um ladrão que forçava viajantes a se encaixarem em sua cama — esticando-os se fossem curtos ou cortando suas pernas se fossem altos. Analogamente, a análise de Procrustes “encaixa” formas uma na outra por transformações rígidas (translação, rotação, escala) minimizando o “desconforto” (distância) entre pontos correspondentes.

4 Agrupamento (Clustering) de Formas

Agora que sabemos medir dissimilaridades entre formas, como agrupá-las?

4.1 O Que é Análise de Agrupamentos?

Definição Operacional

Dado um conjunto de n objetos (formas), queremos particioná-los em K grupos $G_1, G_2, \dots, G_K$ tal que:

1. Formas dentro do mesmo grupo são “similares”
2. Formas em grupos diferentes são “dissimilares”

“Similaridade” é medida por uma função de distância — no nosso caso, a distância riemanniana entre formas.

4.2 Métodos Hierárquicos vs. Particionais

Existem duas grandes famílias:

1. **Hierárquicos:** Constroem uma árvore (dendrograma) aninhando grupos sucessivamente
 - Vantagem: Não precisam especificar K *a priori*
 - Desvantagem: Pode ser computacionalmente caro ($O(n^3)$)
2. **Particionais:** Dividem diretamente em K grupos
 - Vantagem: Mais eficientes computacionalmente
 - Desvantagem: Requerem K pré-especificado

O artigo foca em métodos particionais: K-médias, CLARANS e Hill Climbing.

5 Métodos de Agrupamento Detalhados

5.1 K-médias (K-means)

Intuição do K-médias

Imagine jogar K pontos aleatoriamente no espaço (centroides). Depois:

1. Cada objeto “escolhe” o centroide mais próximo
2. Cada centroide se move para o centro médio dos objetos que o escolheram
3. Repetir até convergir

Definição 5.1 (Critério WSS). O K-médias minimiza a soma de quadrados dentro dos grupos (WSS):

$$W = \sum_{r=1}^K \sum_{i \in G_r} \text{Dist}^2(X_i, \mu_r) \quad (6)$$

onde μ_r é a média (centroide) do grupo r .

Adaptação para Formas

No espaço euclidiano, a média é simples: $\mu_r = \frac{1}{|G_r|} \sum_{i \in G_r} X_i$. Mas em espaço de formas? A “média” é a **média de Procrustes completa**, calculada iterativamente (Algoritmo 1 do artigo)!

Problemas do K-médias:

- Sensível a *outliers* (valores atípicos puxam centroides)
- Converge para ótimos locais (depende da inicialização)
- Assume grupos esféricos (no espaço de formas, isso é uma aproximação)

5.2 CLARANS: Clustering baseado em Medoides

Definição 5.2 (Medoide). Um **medoide** é um objeto real do conjunto de dados (não uma média artificial) que minimiza a dissimilaridade total para os outros objetos do seu grupo.

Formalmente, para um grupo G_r , o medoide m_r satisfaz:

$$m_r = \arg \min_{j \in G_r} \sum_{i \in G_r} d(X_i, X_j) \quad (7)$$

K-médias vs. CLARANS

- K-médias: Centroide pode ser um ponto “vazio” (média de formas não é uma forma real)
- CLARANS: Medoide é sempre uma forma existente no conjunto de dados

Isso torna CLARANS mais robusto a *outliers* e mais interpretável.

O Algoritmo CLARANS:

1. Trata o conjunto de dados como um grafo onde nós são conjuntos de K medoides
2. Cada nó tem vizinhos que diferem por apenas um medoide
3. Faz busca aleatória (randomizada) neste grafo
4. Parâmetros importantes:
 - `numlocal`: número de buscas locais
 - `maxneighbor`: máximo de vizinhos examinados

5.3 Hill Climbing (Subida/descida da encosta)

Analogia da Montanha

Imagine uma paisagem montanhosa onde a altitude representa a qualidade do agrupamento (menor altitude = melhor agrupamento). O algoritmo:

1. Começa em uma posição aleatória (partição inicial)
2. Olha para os “vizinhos” (partições similares)
3. Se algum vizinho for “mais baixo” (melhor), move-se para lá
4. Para quando todos os vizinhos são “mais altos” (pior)

É um algoritmo ganancioso (*greedy*) que encontra ótimos locais.

Definição 5.3 (Critério TD (Total Dissimilarity)). Para Hill Climbing com medoides:

$$TD = \sum_{r=1}^K \sum_{i \in G_r} d(X_i, m_r) \quad (8)$$

O algoritmo aceita movimentos que diminuam TD .

6 O Método Bagging

6.1 Motivação: Por que Bagging?

O Problema da Instabilidade

Algoritmos de agrupamento são frequentemente instáveis:

- Pequenas mudanças nos dados podem levar a agrupamentos muito diferentes
- Inicializações aleatórias podem levar a ótimos locais diferentes
- *Outliers* podem distorcer resultados

Ideia do Bagging: Ao invés de confiar em uma única execução, executar múltiplas vezes e “votar”.

6.2 Bootstrap: Fundamento Teórico

Definição 6.1 (Amostra Bootstrap). Dada uma amostra original $\mathcal{X} = \{X_1, \dots, X_n\}$, uma **amostra bootstrap** $\mathcal{X}^*$ é obtida por amostragem **com reposição** de tamanho n :

$$\mathcal{X}^* = \{X_1^*, \dots, X_n^*\}, \quad X_i^* \stackrel{iid}{\sim} \text{Uniforme}(\mathcal{X})$$

Exemplo 6.1 (Bootstrap em Ação). Amostra original: $\{A, B, C, D, E\}$ (5 objetos)
Amostra bootstrap possível: $\{A, A, B, D, D\}$

- A e D aparecem duplicados
- C e E não aparecem (fora da amostra, 37% esperado)

6.3 Bagging para Agrupamento (BagClust1)

Algorithm 1 BagClust1 para Formas 3D

Require: Conjunto de dados $\mathcal{X}$, algoritmo de agrupamento $\mathcal{A}$, número de réplicas B

Ensure: Agrupamento final $\hat{G}$

```
1:  $n \leftarrow |\mathcal{X}|$ 
2: for  $b = 1, 2, \dots, B$  do
3:    $\mathcal{X}^{(b)} \leftarrow$  amostra bootstrap de  $\mathcal{X}$ 
4:    $G^{(b)} \leftarrow \mathcal{A}(\mathcal{X}^{(b)})$  ▷ Agrupamento na réplica  $b$ 
5: end for
6: Fase de Consenso:
7: for cada objeto  $X_i \in \mathcal{X}$  do
8:   Contar votos:  $v_{ir} = \sum_{b=1}^B \mathbb{I}(X_i \in G_r^{(b)})$ 
9:   Atribuir  $X_i$  ao grupo com mais votos:  $\hat{g}_i = \arg \max_r v_{ir}$ 
10: end for
11: return  $\hat{G} = (\hat{g}_1, \dots, \hat{g}_n)$ 
```

Observação 6.1 (Por que funciona?). • Cada réplica bootstrap é uma “visão ligeiramente diferente” dos dados

- Padrões verdadeiros persistem em todas as réplicas
- Ruído/*outliers* aparecem em poucas réplicas
- Votação majoritária suprime ruído e amplifica sinal

7 Validação de Agrupamentos

Como saber se o agrupamento é “bom”?

7.1 Índice de Rand (RI)

Definição 7.1 (Índice de Rand). Dado um agrupamento estimado $\hat{G}$ e um agrupamento verdadeiro (ou de referência) G , o **Índice de Rand** mede a proporção de pares de objetos classificados consistentemente:

$$RI = \frac{a + b}{\binom{n}{2}} \quad (9)$$

onde:

- a = número de pares no mesmo grupo em $\hat{G}$ e em G
- b = número de pares em grupos diferentes em $\hat{G}$ e em G

Exemplo Numérico

Considere 4 objetos: $\{1, 2, 3, 4\}$

Agrupamento verdadeiro: $\{\{1, 2\}, \{3, 4\}\}$

Agrupamento estimado: $\{\{1, 3\}, \{2, 4\}\}$

Pares possíveis (6 total):

- $(1, 2)$: mesmo grupo no verdadeiro, diferente no estimado
- $(1, 3)$: diferente no verdadeiro, mesmo no estimado
- $(1, 4)$: diferente nos dois $\rightarrow b += 1$
- $(2, 3)$: diferente nos dois $\rightarrow b += 1$
- $(2, 4)$: diferente no verdadeiro, mesmo no estimado
- $(3, 4)$: mesmo no verdadeiro, diferente no estimado

Tempos $a = 0$ (nenhum par coincidente) e $b = 2$, então $RI = 2/6 \approx 0.33$.

Interpretação: $RI \in [0, 1]$, onde 1 = concordância perfeita.

7.2 Índice de Fowlkes-Mallows (FMI)

Definição 7.2 (Fowlkes-Mallows Index). Define-se:

- TP = verdadeiros positivos (pares no mesmo grupo nos dois agrupamentos)
- FP = falsos positivos (pares juntos no estimado, separados no verdadeiro)
- FN = falsos negativos (pares separados no estimado, juntos no verdadeiro)

$$FMI = \frac{TP}{\sqrt{(TP + FP)(TP + FN)}} \quad (10)$$

Observação 7.1 (RI vs. FMI). • Ambos em $[0, 1]$, onde 1 é perfeito

- RI considera tanto concordâncias positivas (juntos) quanto negativas (separados)
- FMI é mais sensível a estrutura de grupos (similar a precisão/recall)
- No artigo, ambos fornecem resultados similares

7.3 Teste de Wilcoxon Pareado

Para comparar métodos (com vs. sem Bagging), o artigo usa o teste de Wilcoxon:

Hipóteses do Teste

- H_0 : Método sem Bagging = Método com Bagging (medianas iguais)
- H_1 : Método sem Bagging < Método com Bagging (Bagging é melhor)

Teste unilateral com $\alpha = 0.05$.

8 Estudo de Simulação do Artigo

8.1 Design Experimental

Cenários Simulados

Figuras-base: Cubo e Paralelepípedo com $k = 8$ marcos

Geração de dados:

1. Selecionar forma-base (cubo ou paralelepípedo)
2. Adicionar ruído normal isotrópico ou anisotrópico
3. Aplicar rotação aleatória (distribuição von Mises)

Cenários:

- **Isotropia:** $\Sigma = \sigma^2 I$ (mesma variabilidade em todas as direções)
- **Anisotropia:** Σ com estrutura de covariância direcional
- Dispersões: baixa ($\sigma = 3$), média ($\sigma = 6$), alta ($\sigma = 9$)

8.2 Resultados Principais

Tabela 1: Resumo dos Resultados de Simulação

Cenário	Algoritmo	Benefício do Bagging	Comentário
3*Isotropia	K-médias	Parcial	Apenas alta dispersão
	CLARANS	Sim	Todos os cenários
	Hill Climbing	Sim	Todos os cenários
3*Anisotropia	K-médias	Não	Nenhum ganho significativo
	CLARANS	Sim	Média/alta dispersão
	Hill Climbing	Sim	Média/alta dispersão

Interpretação dos Resultados

Por que CLARANS e Hill Climbing beneficiam-se mais?

1. Ambos usam **medoides** (não médias), herdando robustez do PAM
2. O parâmetro `maxneighbor` pequeno em CLARANS limita a busca; Bagging compensa essa limitação
3. K-médias já é mais estável (usa médias), então ganhos do Bagging são marginais

Por que baixa dispersão não beneficia do Bagging? Quando os grupos são bem separados (σ pequeno), todos os algoritmos encontram a solução correta facilmente — não há instabilidade para corrigir.

9 Aplicações em Dados Reais

9.1 Crânios de Macacos ($N = 18$)

- 9 machos vs. 9 fêmeas
- $k = 7$ marcos anatômicos
- **Resultado:** K-médias não beneficiou do Bagging (conjunto pequeno e bem separado)

9.2 Cérebros Humanos ($N = 58$)

- 43 destros vs. 15 canhotos
- $k = 24$ marcos (12 por hemisfério)
- **Resultado:** Todos os métodos beneficiaram-se do Bagging (ganhos 11–31%)

Observação 9.1 (Lição Prática). O tamanho da amostra e a complexidade da separação influenciam o ganho do Bagging. Conjuntos maiores e mais “confusos” tendem a se beneficiar mais.

10 Conclusões e Recomendações Práticas

10.1 Checklist para Aplicação

- ✓ Pré-processamento: Definir marcos anatômicamente relevantes
- ✓ Remover efeitos de pose: Aplicar Procrustes (translação, escala, rotação)
- ✓ Calcular distâncias: Usar distância riemanniana no espaço de formas
- ✓ Escolher K : Hierárquico ou conhecimento do domínio
- ✓ Escolher algoritmo:
 - Se preocupado com *outliers*: CLARANS ou Hill Climbing
 - Se precisar de velocidade: K-médias
- ✓ Aplicar Bagging se:
 - Conjunto de dados é moderadamente grande ($N > 30$)
 - Há indícios de instabilidade em execuções repetidas
 - Usando CLARANS com `maxneighbor` pequeno
- ✓ Validar: Usar RI e/ou FMI se tiver rótulos de referência

10.2 Extensões Futuras

- **Boosting:** Em vez de amostras aleatórias, focar em objetos “difíceis” de agrupar
- **Random Forests para Clustering:** Combinar subespaços aleatórios com agrupamento
- **Paralelização:** Execuções bootstrap são independentes — perfeitas para GPUs

11 Glossário de Termos

Marco (Landmark)

Ponto anatômico ou geométrico identificável em uma forma

Configuração

Conjunto de marcos representados como matriz $k \times m$

Pré-forma

Configuração após remoção de translação e escala

Espaço de Formas

Conjunto de classes de equivalência de formas sob similaridades euclidianas

Variedade Riemanniana

Espaço suave onde se pode medir distâncias e ângulos

Espaço Estratificado

Espaço com regiões de suavidade separadas por singularidades

Medoide

Objeto real do conjunto de dados que representa o centro de um grupo

Centroide

Ponto médio (pode não ser um objeto real)

Bootstrap

Amostragem com reposição do conjunto original

Bagging

Bootstrap Aggregating — técnica de ensemble

Índice de Rand

Medida de concordância entre dois agrupamentos

Anisotropia

Diferente variabilidade em diferentes direções

12 Referências e Leituras Complementares

1. **Texto básico:** Dryden, I.L. & Mardia, K.V. (2016). *Statistical Shape Analysis*, 2nd ed. Wiley.
2. **Artigo principal:** Nascimento, I., Ospina, R. & Amorim, G. (2024). Using Bagging to improve clustering methods in the context of three-dimensional shapes. *Advances in Data Analysis and Classification*.
3. **Fundamentos:** Kendall, D.G. (1984). Shape manifolds, Procrustean metrics, and complex projective spaces. *Bulletin of the London Mathematical Society*.
4. **Bagging:** Breiman, L. (1996). Bagging predictors. *Machine Learning*.
5. **CLARANS:** Ng, R.T. & Han, J. (2002). CLARANS: A method for clustering objects for spatial data mining. *IEEE TKDE*.