

Roteiro de Apresentação

Using Bagging to improve clustering methods in the context of
three-dimensional shapes

Nascimento, Ospina & Amorim (2024)

Caio Araújo & Marina Oliveira

Programa de Pós-Graduação em Estatística — UFPE

Junho de 2026

Resumo

Divisão adotada (Alternativa A): **Marina** — slides **1–2** e **3–7** (abertura e introdução); **Caio** — slides **8–26** (desafio geométrico, objetivos, background, algoritmos, Bagging e simulação); **Marina** — slides **26–46** (resultados, dados reais e conclusões). O PDF `bagging_slides_unico.pdf` tem **46 slides**. Duração alvo: **35–40 minutos** + perguntas. Inclui seção **Q & A** com perguntas prováveis da plateia e do professor e respostas sugeridas.

Sumário

1	Visão geral da divisão	2
1.1	Mapa rápido por seção do PDF	2
2	Materiais de estudo por apresentador	3
2.1	O que Marina deve dominar (slides 1–7 e 26–46)	3
2.2	O que Caio deve dominar (slides 8–26)	3
3	Roteiro slide a slide	4
3.1	Slides 1–7 — Marina Oliveira (abertura e introdução)	4
3.2	Slides 8–12 — Caio Araújo (fechamento da intro e início do background)	4
3.3	Slides 13–26 — Caio Araújo (teoria, métodos e simulação)	4
3.4	Slides 26–46 — Marina Oliveira (resultados e encerramento)	5
4	Checklist de ensaio (ambos)	6
5	Q & A — Perguntas e respostas sugeridas	6
5.1	Conceitos e motivação (SSA, formas 3D)	6
5.2	Métodos, algoritmos e BagClust1	7
5.3	Simulação, métricas e inferência	9
5.4	Resultados em dados reais	10
5.5	Perguntas críticas (professor / banca)	11
5.6	Perguntas rápidas da plateia	12
6	Clipes Manim (opcionais)	13

1 Visão geral da divisão

Tabela 1: Resumo da divisão — Alternativa A (números = slides do PDF)

Faixa	Conteúdo	Quem	Tempo est.
1–2	Capa e sumário	Marina	1–2 min
3–7	Introdução (SSA, agrupamentos, aplicações, literatura)	Marina	6–7 min
8–12	Desafio 3D, Bagging na literatura, objetivos, início do background	Caio	4–5 min
13–26	Fundamentos, algoritmos, Bagging e simulação	Caio	14–16 min
26–46	Resultados, dados reais, conclusões e referências	Marina	14–16 min
Total			35–40 min

Dica para a apresentação

Transição Marina → Caio (slide 8): “Depois de situar o artigo na literatura, o Caio explica por que formas 3D exigem métodos específicos e como o trabalho se propõe a resolvê-lo.”

Slide 26 (passagem Caio → Marina): Caio encerra com *Formas simuladas*; Marina entra com “Com esse desenho experimental, vejamos se o Bagging melhora os métodos” e segue no slide 27.

1.1 Mapa rápido por seção do PDF

Slides	Seção	Quem	Tema
1–2	—	Marina	Capa e sumário
3–7	Intro	Marina	SSA, agrupamentos, aplicações, revisão literária
8–10	Intro (cont.)	Caio	Desafio central, Bagging na literatura, objetivos
11–12	Background	Caio	Fundamentos (início)
13–15	Background	Caio	Pré-forma, Procrustes, distâncias
16–19	Algoritmos	Caio	K-means, CLARANS, Hill Climbing
20–21	Bagging	Caio	Conceito e BagClust1
22–26	Simulação	Caio	Desenho experimental e figuras
27–35	Resultados	Marina	Tabelas, violinos, síntese
36–41	Dados reais	Marina	Macacos e cérebros
42–43	Conclusões	Marina	Síntese e trabalhos futuros
44–46	Referências	—	Backup

2 Materiais de estudo por apresentador

2.1 O que Marina deve dominar (slides 1–7 e 26–46)

1. **Slides 1–2:** apresentar o artigo (Nascimento et al., 2024), autores e estrutura do sumário.
2. **Slide 3** — SSA: ramo da estatística para representações geométricas; geometria como informação relevante (Dryden & Mardia, 2016).
3. **Slide 4** — Agrupamento particional: K-means, CLARANS, Hill Climbing (visão geral; Everitt et al., 2011).
4. **Slide 5** — Aplicações: medicina, biologia, engenharia, arqueologia (Adams & Otárola-Castillo, 2013; Brignell et al., 2010).
5. **Slide 6** — Representação por marcos; definição de forma; objetivo do artigo.
6. **Slide 7** — Revisão literária 2D→3D: Amaral, Assis, Vinué, Nascimento et al.; lacuna CLARANS/HC em 3D.
7. **Slides 27–35** — Resultados da simulação: Tabelas 1–6, Figuras 3–4; mensagem por σ .
8. **Slides 36–41** — Dados reais: ganho relativo; Tabelas 7–8; Figuras 5–8.
9. **Slides 42–43** — Conclusões, trabalhos futuros; encerramento.

2.2 O que Caio deve dominar (slides 8–26)

1. **Slides 8–10** — Fechamento da introdução: espaço estratificado (desafio central); antecedentes do Bagging (Breiman, Dudoit, Assis); objetivos e contribuição de Nascimento et al. (2024).
2. **Slides 11–12** — Início do background: marcos, configuração X ; por que não usar distância euclidiana.
3. **Slides 13–15** — Fundamentos (Seção 2): pré-forma $Z = HX/\|HX\|$, classe $[Z]$, distâncias ρ , d_F , média de Fréchet.
4. **Slides 16–19** — Algoritmos (Seção 3): K-means, CLARANS, Hill Climbing.
5. **Slides 20–21** — BagClust1: bootstrap, votação, $B = 100$. *Opcional:* `manim/output/clip05_bagclust1.mp4`.
6. **Slides 22–26** — Simulação (Seção 4.1): cubo/paralelepípedo, cenários, RI/FMI, Wilcoxon; Figuras 1–2.

3 Roteiro slide a slide

3.1 Slides 1–7 — Marina Oliveira (abertura e introdução)

Sl.	Título no PDF	Quem	O que falar / estudar
1	Capa	Marina	Cumprimentar a plateia; título do artigo e apresentadoras.
2	Sumário	Marina	Percorrer as seções; antecipar estrutura da talk.
3	Análise estatística de formas	Marina	SSA: geometria como informação; agrupamento em 3D.
4	Análise de agrupamentos	Marina	Particionais; três algoritmos do artigo (visão geral).
5	Aplicações da análise de formas	Marina	Medicina, biologia, engenharia, arqueologia; figuras.
6	Representação geométrica e agrupamento	Marina	Marcos $k \times m$; forma; objetivo (Bagging em 3D).
7	Revisão: formas 2D $\rightarrow$ 3D	Marina	Tabela literária; lacuna; preparar passagem para Caio.

*Transição $\rightarrow$ Caio (slide 8): ver caixa **Dica** na Seção 1.*

3.2 Slides 8–12 — Caio Araújo (fechamento da intro e início do background)

Sl.	Título	Quem	O que falar / estudar
8	Desafio central	Caio	Espaço estratificado; singularidades; métricas adequadas.
9	Bagging em agrupamento: antecedentes	Caio	Breiman, Leisch, Dudoit, Assis (2D); motivação para 3D.
10	Objetivos e contribuição	Caio	Três objetivos; lacuna (Vinué só K-means).
11	Fundamentos da análise de formas	Caio	Marcos; espaço de formas; Kendall (1977).
12	Por que não similaridade euclidiana?	Caio	Translação, escala, rotação; pipeline Helmert.

Clipe sugerido após slide 12: clip01_mesma_forma.mp4

3.3 Slides 13–26 — Caio Araújo (teoria, métodos e simulação)

Sl.	Título	Quem	O que falar / estudar
13	Pré-forma e remoção de efeitos	Caio	Eq. (1): $Z = HX/\ HX\ $; Helmert.

Sl.	Título	Quem	O que falar / estudar
14	Forma e análise de Procrustes	Caio	$[Z] = \{Z\Gamma\}$; singularidades em 3D.
15	Distâncias e forma média	Caio	Def. 4–6: ρ , d_F , média de Fréchet.
16	Agrupamento de formas tridimensionais	Caio	Notação $\mathcal{X}$, partição G .
17	3.1 K-means para formas 3D	Caio	WSS (eq. 4); forma média.
18	3.2 CLARANS para formas 3D	Caio	Medoides; parâmetros do algoritmo.
19	3.3 Hill Climbing para formas 3D	Caio	Critério TD ; ótimos locais.
<i>Clipe sugerido: clip04_instabilidade.mp4</i>			
20	Bagging: conceito e motivação	Caio	Ensemble; BagClust1; $B = 100$.
21	Procedimento BagClust1	Caio	Bootstrap, votação, consenso.
<i>Clipe sugerido: clip05_bagclust1.mp4</i>			
22	Avaliação numérica	Caio	Comparação com/sem Bagging; parâmetros.
23	Geração dos dados simulados	Caio	Cubo e paralelepípedo; von Mises.
24	Cenários de dispersão	Caio	Isotropia/anisotropia; $\sigma \in \{3, 6, 9\}$.
25	Desenho experimental e validação	Caio	50 réplicas MC; RI/FMI; Wilcoxon.
26	Formas simuladas	Caio	Figuras 1–2; passagem de voz para Marina.

3.4 Slides 26–46 — Marina Oliveira (resultados e encerramento)

Sl.	Título	Quem	O que falar / estudar
26	Formas simuladas	Caio / Marina	Handoff: Caio nas figuras; Marina introduz resultados.
27	Efeito do Bagging na simulação	Marina	Mensagem-chave por σ ; CLARANS/HC.
<i>Clipe sugerido: clip06_ganho.mp4</i>			
28–30	Resultados: Isotropia (3 tabelas)	Marina	Destacar p -values em $\sigma = 6, 9$.
31	Isotropia: Violin Plots	Marina	Fig. 3.
32–34	Resultados: Anisotropia (3 tabelas)	Marina	Padrão semelhante.
35	Anisotropia: Violin Plots	Marina	Fig. 4.
36	Ganho relativo	Marina	Fórmula (%); uso nos dados reais.

Sl.	Título	Quem	O que falar / estudar
37	Aplicação a dados reais	Marina	Macacos e cérebros.
38	Crânios de macacos	Marina	Tabela 7.
39	Macacos: Agrupamento nas PCs	Marina	Fig. 6.
40	Cérebros humanos	Marina	Tabela 8.
41	Cérebros: Agrupamento nas PCs	Marina	Fig. 8.
42	Conclusões	Marina	Síntese dos resultados.
43	Trabalhos futuros	Marina	“Obrigado! Perguntas?”
44–46	Referências	—	Backup.

4 Checklist de ensaio (ambos)

1. Transições obrigatórias a ensaiar

- **Marina** → **Caio** (slide 7 → 8): literatura → desafio geométrico e objetivos.
- **Caio** → **Marina** (slide 26 → 27): simulação → resultados.

2. Q&A — quem responde o quê (detalhes na Seção 5)

- **Marina**: SSA, aplicações, revisão literária, tabelas, violinos, dados reais, conclusões.
- **Caio**: desafio 3D, fundamentos, distâncias, algoritmos, BagClust1, desenho da simulação.

3. Mensagens que não podem faltar

- Formas 3D $\Rightarrow$ espaço não euclidiano / estratificado.
- Bagging reduz variância e mitiga ótimos locais.
- Maior benefício com dispersão média-alta e dados complexos (cérebros).
- Trade-off: acurácia vs. custo computacional ($B = 100$).

5 Q & A — Perguntas e respostas sugeridas

Use as respostas abaixo como roteiro de ensaio. A coluna **Quem** indica quem deve conduzir a resposta (o outro apresentador pode complementar).

5.1 Conceitos e motivação (SSA, formas 3D)

Pergunta	Quem	Resposta sugerida
Por que não basta aplicar K-means diretamente nas coordenadas dos marcos?	Caio	Porque a matriz $k \times 3$ depende de translação , escala e rotação . Duas formas iguais podem ter coordenadas muito diferentes. O artigo remove esses efeitos (Helmert + normalização) e trabalha no espaço de formas , com distância riemanniana — não euclidiana nas coordenadas brutas.
O que significa dizer que o espaço de formas 3D é <i>estratificado</i> ?	Caio	Em 3D, o espaço de formas Σ_m^k não é uma variedade suave: há singularidades (regiões onde a geometria muda). Isso dificulta médias e distâncias “ingênuas”. Por isso usamos Procrustes, distância riemanniana e média de Fréchet — ferramentas adequadas à geometria do problema.
Qual a diferença entre marcos, pré-forma e forma?	Marina	Marcos : pontos $k \times m$ no espaço. Pré-forma $Z = HX/\ HX\ $: remove translação e escala. Forma $[Z]$: classe de equivalência sob rotação. O agrupamento compara formas , não configurações brutas.
Por que o artigo foca em agrupamento <i>particional</i> e não hierárquico?	Marina	Os autores comparam três métodos particionais clássicos (K-means, CLARANS, Hill Climbing) adaptados ao contexto 3D. Quando K é desconhecido, a literatura sugere métodos hierárquicos (Everitt et al.), mas aqui $K = 2$ é conhecido na simulação e nos dados reais — o foco é avaliar estabilidade dos particionais com Bagging.
Quais são as aplicações práticas deste trabalho?	Marina	Morfometria em medicina (cérebro, órgãos), biologia (classificação por morfologia), engenharia (controle de qualidade 3D) e arqueologia (comparação de artefatos). O artigo ilustra com crânios de macacos e cérebros humanos.

5.2 Métodos, algoritmos e BagClust1

Pergunta	Quem	Resposta sugerida
Qual a diferença entre K-means, CLARANS e Hill Climbing neste contexto?	Caio	Os três minimizam dissimilaridade no espaço de formas, mas diferem na representação do centro do grupo: K-means usa centroides (média de Fréchet); CLARANS e Hill Climbing usam medoides (objetos reais). CLARANS faz busca aleatorizada; Hill Climbing é busca local gananciosa — ambos podem cair em ótimos locais .
Por que Bagging ajuda especificamente CLARANS e Hill Climbing?	Caio	Esses algoritmos são mais instáveis : dependem de inicialização e de parâmetros como maxneighbor pequeno no CLARANS. O Bagging gera $B = 100$ amostras bootstrap, agrupa em cada uma e faz consenso por votação , reduzindo variância e suavizando decisões afetadas por outliers ou ótimos locais.
Como funciona o BagClust1 passo a passo?	Caio	(1) Gerar B amostras bootstrap com reposição; (2) aplicar o algoritmo base em cada amostra; (3) alinhar rótulos entre partições (permutações); (4) para cada objeto, atribuir o rótulo mais votado ; (5) em empate, escolha aleatória. É o procedimento de Dudoit & Fridlyand (2003), adaptado por Nascimento et al. a formas 3D.
Por que $B = 100$ e não outro valor?	Caio	Dudoit usava $B = 20$; os autores aumentaram para $B = 100$ buscando maior estabilidade, aceitando custo computacional maior. Não há estudo sistemático de sensibilidade a B no artigo — é uma limitação e possível trabalho futuro. Em aplicações, pode-se testar valores menores se o tempo for crítico.
Por que não usar Random Forest ou Boosting em vez de Bagging?	Caio	Bagging é o ensemble mais estudado para estabilizar agrupamento (Breiman; Dudoit). Os autores deixam Boosting, Random Subspace e Random Patches como trabalhos futuros — comparação de desempenho e custo ainda não foi feita neste contexto 3D.

Pergunta	Quem	Resposta sugerida
Como se alinham os rótulos entre as B partições?	Caio	Partições bootstrap podem trocar os rótulos dos grupos (grupo 1 vira grupo 2). Antes da votação, aplica-se permutação de rótulos para maximizar concordância com uma partição de referência (ou entre réplicas). Sem isso, a votação seria inconsistente.
O K-means também não é instável? Por que o Bagging ajuda menos nele?	Caio	K-means já usa médias e tende a ser mais estável na simulação, especialmente com baixa dispersão. Os ganhos com Bagging são limitados em $\sigma = 3$ e moderados em $\sigma = 9$. Nos cérebros ($N = 58$, dados mais complexos), até o K-means se beneficiou (11% em RI).

5.3 Simulação, métricas e inferência

Pergunta	Quem	Resposta sugerida
Como os dados simulados foram gerados?	Caio	Duas formas-base: cubo e paralelepípedo com $k = 8$ marcos. Simula-se $\mathbf{X} \sim \mathcal{N}_{3k}(\boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)$ no espaço de marcos, com rotação aleatória (von Mises). Cenários isotrópicos ($\boldsymbol{\Sigma} = \sigma^2 I$) e anisotrópicos ($\gamma = 4$), com $\sigma \in \{3, 6, 9\}$.
Por que cubo e paralelepípedo? Não é um cenário artificial?	Caio	Sim, é um desenho controlado (seguindo Vinué et al., 2014): grupos verdadeiros conhecidos permitem calcular RI e FMI. A limitação é que formas reais são mais irregulares — por isso o artigo valida também em dados reais (macacos e cérebros).
O que são RI e FMI?	Marina	Rand Index (RI) : proporção de pares de objetos concordantes entre agrupamento obtido e verdadeiro ($\in [0, 1]$). Fowlkes–Mallows (FMI) : mede concordância de pares no mesmo grupo (mais sensível à estrutura de clusters). Ambos = 1 significa concordância perfeita.

Pergunta	Quem	Resposta sugerida
Por que Wilcoxon pareado e não t -test?	Marina	Comparam-se as 50 réplicas de Monte Carlo (com vs. sem Bagging) por cenário. O Wilcoxon não assume normalidade das diferenças e é adequado para amostras pareadas de índices com distribuição assimétrica. H_1 : método sem Bagging é pior que com Bagging ($\alpha = 5\%$).
Em $\sigma = 3$ quase todos os métodos atingem RI= 1. O Bagging ainda importa?	Marina	Com baixa dispersão , os grupos são bem separados — todos os métodos já acertam. O Bagging traz pouco ganho (e às vezes p -value alto). O benefício aparece com dispersão média/alta ($\sigma = 6, 9$), quando RI e FMI caem e a instabilidade cresce.
Isotropia vs. anisotropia: o padrão de resultados muda?	Marina	O padrão qualitativo se mantém: CLARANS e Hill Climbing ganham mais com Bagging; K-means ganha menos. Anisotropia torna o problema mais difícil (variabilidade direcional), mas não inverte a conclusão principal.

5.4 Resultados em dados reais

Pergunta	Quem	Resposta sugerida
Por que nos macacos o K-means não melhorou com Bagging?	Marina	Conjunto pequeno ($N = 18$, $k = 7$): pouca variabilidade amostral no bootstrap. RI não mudou; ganhos aparecem sobretudo no FMI para CLARANS (+10,8%) e Hill Climbing (+21,9%). Amostras pequenas limitam o efeito do ensemble.
Por que nos cérebros todos os métodos melhoraram muito?	Marina	$N = 58$, $k = 24$ marcos — dados maiores e mais complexos (destros vs. canhotos). Maior sobreposição entre grupos e mais instabilidade. Ganhos de 11–31% em RI/FMI; CLARANS com +31% no FMI. Confirma que Bagging compensa quando há mais “ruído” e variância.

Pergunta	Quem	Resposta sugerida
Os agrupamentos recuperaram os rótulos biológicos corretos?	Marina	O artigo avalia concordância com sexo (macacos) e lateralidade (cérebros) via RI/FMI — não afirma separação perfeita. Nos cérebros, RI sobe de $\sim 0,50$ para $\sim 0,58$ com Bagging: melhora clara, mas ainda há erro — o problema é difícil e os grupos podem não ser totalmente separáveis pela morfologia.
O que é ganho relativo e por que não usaram Wilcoxon nos dados reais?	Marina	Ganho relativo = $100 \times (\text{índice com Bagging} - \text{sem}) / \text{sem}$. Nos dados reais há uma única execução por método (sem 50 réplicas), então não há distribuição amostral para Wilcoxon — usa-se o ganho percentual para comparar métodos.

5.5 Perguntas críticas (professor / banca)

Pergunta	Quem	Resposta sugerida
Qual a principal contribuição em relação a Vinué et al. (2014)?	Marina	Vinué adaptou apenas K-means a formas 3D. Nascimento et al. estendem a CLARANS e Hill Climbing e introduzem Bagging (BagClust1) nesse contexto — lacuna que o slide 7 destaca.
O custo computacional não inviabiliza o método?	Caio	Sim, é o principal trade-off : $B = 100$ vezes o custo de cada algoritmo. Cada réplica bootstrap é independente — paralelização é direção natural (trabalho futuro dos autores). Para N moderado e análises morfométricas, o ganho em estabilidade pode justificar o custo.
O artigo compara com métodos hierárquicos ou espectrais?	Caio	Não. Foco em três particionais adaptados. Métodos hierárquicos entram na discussão quando K é desconhecido, mas não fazem parte do estudo comparativo.
E se K for desconhecido na prática?	Caio	O artigo menciona agrupamento hierárquico nesse caso. BagClust1 pressupõe K fixo (como na maioria dos particionais). Escolher K (silhueta, gap, conhecimento do domínio) permanece pré-requisito .

Pergunta	Quem	Resposta sugerida
As conclusões generalizam para outras formas além de cubo/paralelepípedo?	Marina	A simulação é controlada ; a generalização vem dos dados reais (macacos, cérebros). Não há garantia universal — recomenda-se Bagging quando há indícios de instabilidade, N maior e dispersão moderada/alta.
Por que não testar B variável ou validação cruzada?	Caio	Limitação reconhecida: $B = 100$ é fixo sem análise de sensibilidade. Validação cruzada poderia avaliar estabilidade sem rótulos verdadeiros — os autores usam RI/FMI na simulação e ganho relativo nos reais. Extensões metodológicas ficam para trabalhos futuros.
Objetos com número diferente de marcos ou marcos faltantes?	Caio	O framework assume mesmos k marcos homólogos em todos os objetos (padrão em SSA). Marcos faltantes ou semi-marcos exigem imputação ou modelos alternativos — fora do escopo do artigo.

5.6 Perguntas rápidas da plateia

Pergunta	Quem	Resposta sugerida
Em que linguagem/software o artigo foi implementado?	Caio	R , com pacotes de análise de formas 3D e distância riemanniana (conforme Seção 4 do artigo).
Posso usar Bagging com outros algoritmos de clustering?	Caio	O princípio do BagClust1 é genérico : qualquer particional base pode entrar no ensemble. O artigo testa três escolhas naturais na literatura de formas 2D/3D.
Quando <i>não</i> usar Bagging?	Marina	Quando N é muito pequeno, grupos são muito separados (σ baixo) ou o tempo de computação é limitante. Nesses casos o ganho é marginal e o custo de B execuções não se paga.
Este trabalho é original ou só uma apresentação do artigo?	Marina	É uma apresentação didática do artigo de Nascimento, Ospina e Amorim (2024), com síntese, figuras e animações para a disciplina. A contribuição científica é dos autores do paper.

Dica para a apresentação

Estratégia no Q & A: (1) Repita a pergunta em uma frase; (2) responda a conclusão principal primeiro; (3) cite um número ou resultado (ex.: “CLARANS, $\sigma = 6$, $p < 0,0001$ ”); (4) se não souber, encaminhe ao colega ou diga que o artigo não aborda o ponto.

6 Clipes Manim (opcionais)

Clipe	Após slide	Quem
clip01_mesma_forma.mp4	12	Caio
clip04_instabilidade.mp4	19	Caio
clip05_bagclust1.mp4	21	Caio
clip06_ganho.mp4	27	Marina

Tabela 12: Vídeos em `manim/output/`

Leitura para ensaio: (1) material didático; (2) `bagging_clustering_3D_ptBR.pdf`; (3) slides na ordem do PDF; (4) artigo original para tabelas e equações.